

REAL DEVICE / 真机截图 · 非渲染

iPhone 18 Pro Max · 飞行模式 · 全程离线

截图 2026-11-06 20:30 · 1.7B Q4_K_M
4 轮取后 3 轮 · 4K 上下文

APP PALETTE

AIY 27 / FIELD REPORT

高中组 PRO · 题目一 AI×科学工程（自定方向）

POCKET INTELLIGENCE

口袋里的 Agent 实验室

A local-first agent lab on a phone

数据不出设备，美高课程特训；
日历 / 提醒真的能用，一台 iPhone 跑起来。

不是云端助手的缩小版，
而是学生自己的本地 Agent 工作台。

61.1 tok/s	0 上传	16/16 真机自检
18 Pro Max · 1.7B Q4_K_M	推理全程本机	13 场景 + 3 语音

团队：_____　　演示人：_____　　GitHub：mobile-llm-engine

模型口径：基于 Qwen3 继续训练 · 推理底座 llama.cpp（MIT） · 数字来自本机训练与真机日志

数据一旦离开设备，控制权就没了。

国际学校 / 美高学生每天遇到的不是「AI 不好用」，而是「不敢用」和「没网用」。

DATA OUT

0

云端助手断网可用性

请求离开设备；断网即失效，数据已经出设备

3.29万

ZCode 事件被上传文件

4.11 亿明文字符，项目连同修改历史打包上传

15/15

改前日期题全错

模型没有「今天」锚点，只能靠心算瞎猜

目标用户：国际学校 / 美高在读学生 + 想学 AI 编排的初学者

我们要的不是更聪明的云端，而是能放在口袋里的控制权。

2026 公开事故（节选）

2026.04–06	**Claude Code 安全后门**	未经同意回传地域、身份标识等敏感数据 求是网 / 工信部风险提示
2026.09	**智谱 ZCode 传包风波**	3.29 万个文件、4.11 亿字符，连同修改历史上传 36氪 / 掘金（企业函件）
2026.08	**PROMPTPEEK 侧信道**	共享缓存可还原其他用户的提问内容 NDSS 2025 论文

来源：2026 年公开报道（求是网 / 工信部 NVDB、36氪 / 掘金、NDSS 2025）· 用户调研

一句话，七步，日历里真的多了一条。

从断网到写入，全程发生在手机本地；每一步都可复核。

用户原话 / 飞行模式

「家长会，明天下午三点，学校，约一小时」

01	02	03	04	05	06	07
飞行模式	**本地推理**	**工具调用**	**schema 校验**	**系统确认**	**EventKit 写入**	**回读校验**
手机彻底断网	1.7B 模型在手机里	输出标准 tool_call JSON	参数不对直接拒绝	用户点「允许」才执行	日历里真的多一条	写不进去就如实报错

完全离线

权重与推理都在手机，飞行模式可完整跑通。

工具闭环

不是聊天，是把事办成：日历 / 提醒真实写入系统。

人确认

写入前弹系统确认框，显示可读日期与过期警告。

16/16	21.7s	1804 MB	42–79
真机回归（含 3 语音）	13 场景套件耗时	峰值内存	场景解码 tok/s

断网也能把事办成——这是云端助手给不了的体验。

来源：iOS 演示壳（EngineKit）真机流程 · 16/16 回归（13 场景 + 3 语音）· 2026-11-09 · PIPL：数据不出设备

训练到顶之后，我们把数学交给工具。

1.7B 的数学容量有上限；继续堆数据没用，改用 CAS 做确定性计算。

数学 69 题 / 客观对拍 / 越高越好



SFT26 把 31 道真实 FRQ 训进 1.7B，仍是 47/69；
SFT27e 改走 CAS 工具调用，+11 题。

从真题到验收 / 五步

01 **真题转化**
31 道 AP FRQ，官方评分标准逐题转写

02 **教师合成**
云端大模型 + 配比拼装，12.78M tokens

03 **符号验真**
SymPy 对拍抓 110 条错解，不进训练池

04 **SFT 训练**
双卡 3 epochs；数据量不再是瓶颈

05 **工具验收**
69 题客观集；CAS 路线 58/69

12.78M	31	110	47/69
学术训练 tokens（SFT19）	道真实 FRQ 进训练	条 SymPy 抓出错解	纯训练路线最高分

数据质量不是瓶颈，容量才是；让模型理解与列式，计算交给确定性工具。

来源：SFT19 / SFT25 / SFT26 / SFT27e 评测 · train/lab-notebook/训练线总览（2026-11-09）

同一套代码，
0.6B / 1.7B 都装进 iPhone。

EngineKit 全 Swift 封装 llama.cpp；模型、上下文、速度档都可换，代价写在界面上。

61.1 tok/s

1.7B Q4_K_M · 18 Pro Max · 4K 上下文

1.90 GB

峰值内存（4K 上下文）

4K / 8K / 16K / 32K

KV 约 0.44 / 0.88 / 1.75 / 3.5 GB；8GB 机型建议 ≤8K。

档位	17 PM	18 PM	峰值(18)
1.7B Q4_K_M	38.5	**61.1**	1903 MB
1.7B Q5_K_M	34.2	56.5	2054 MB
1.7B Q8_0	27.3	40.1	2683 MB
0.6B Q5_K_M	86.9	100.5	1187 MB
0.6B Q4_K_M	89.0	119.7	1144 MB
0.6B IQ4_XS	96.7	121.1	1109 MB

MULTI-AGENT CAPACITY / 规划，待实测

8GB 机型

2–3 个 0.6B Agent 同时在线；再开进入内存警戒。

12GB 机型

2 个 1.7B + 1 个 0.6B；记录峰值与被终止次数。

OOM 门禁

每次组合跑分都测「最多几个不 OOM」，超预算自动降档。

18 Pro Max 上 1.7B 稳定 61.1 tok/s；向下兼容 0.6B，向上预留多 Agent 内存预算。

口径：4 轮取后 3 轮均值 · 4K · 均衡档 · 峰值内存单轮最高；17 PM 为同协议对比（2026-11-03）

PHOTO IN, PROOF OUT

拍照做题：公式识别 → 本地 CAS → 可复核答案。

Texo 20M 公式识别 + math.js，在手机上完成「看图 → 题意 → 计算」。

INPUT / 题目图（示例）

$$\lim_{x\to 0}\frac{\sin x}{x}$$

OCR / LaTeX

```
\lim_{x\rarr0}\frac{\sin x}{x}
```

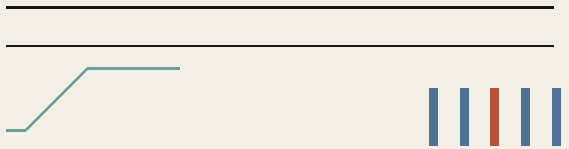
题意 / PARSED

求 ((sin(x))/(x)) 在 x→0 时的极限。

ANSWER / math.js 本机计算

1

数学段单独切 SFT27e；助理段仍用领队 + 工人。



58/69

数学端到端

84.1% · SFT27e

69/69

工具发射

schema 全通过

186ms

公式识别（热）

18 Pro Max

18/18

Mac 对拍

与 Python 逐字一致

一张照片，三个本机步骤：
识别公式 → 转成题意 → 调用 CAS。

没有网络请求，也没有把题目发给云端。

来源：Texo 18 图对拍（2026-11-09）· SFT27e 69 题端到端评测 · iPhone 18 Pro Max 真机自检

40 道工具题，
40/40 全部正确发射。

命题书要求「用测试证明有没有用」——每次工具调用都落成 case 文件。

40/40

tool_call 正确发射

1.7B Q5/Q4 双档 · 30 条训练分布 + 10 条泛化

100%
schema 校验通过

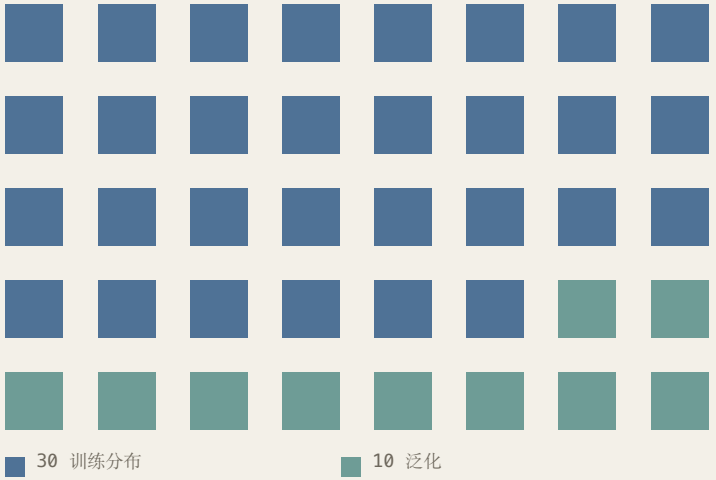
100%
JSON 解析成功

TOOLS / 白名单

`add_calendar_event · add_reminder · translate`
`summarize · clarify`

schema 必填参数 + 时间正则；白名单外直接拒绝；写入前人工确认。

40 CASES / 一格一题



不是「感觉能用」，是逐题可复核；
失败样例也保留，能回放。

40/40 不是全场景全对，是这套 40 题全对。

来源：SFT19 评测（40 题，temp 0.7）· SFT3 工具遵循率专项 · 16/16 真机回归

日期题，
从 15/15 全错到 58/60。

改前 15 题全错；补日期表后把验收集扩到 60 题，再训边界。

58/60

日期题精确匹配 · SFT20d

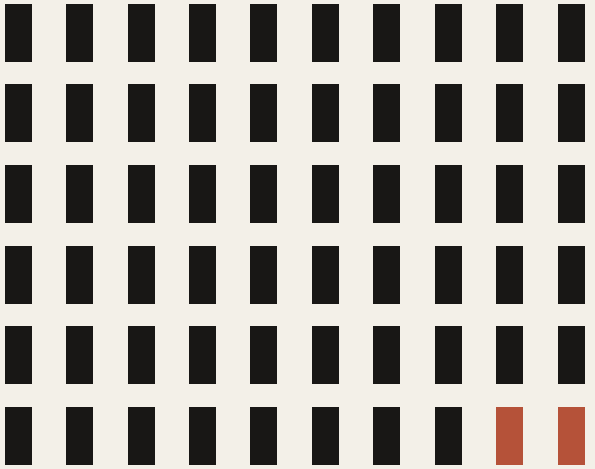
上一版 SFT20c 93.3%；这一版 96.7%。

96.7%	60 题日期集（SFT20d）
16/16	边界题：闰日 / 跨年 / 跨月 / 小时进位
8/8	工人四工种回归

日期表由引擎注入，不让模型心算日历。

剩下的 2 题写进限制，不假装 100%。

60 题 / 一格一题 / 58 对 2 错



仍错 2 题 / 写进产品限制

2027-02-29 不存在 → 应滚到 2028

23:30 + 3h 跨天 → 只加了 1h

能答的答，不能答的交给确认框。

来源：SFT20b / SFT20c / SFT20d 日期评测（60 题，2026-11-08）· 训练线总览

AI 判断错了，产品怎么办?

命题书完成重点：怎样提醒使用者、由谁确认和处理。

风险	产品怎么提醒	谁确认 / 处理
日期 / 事实幻觉	结果卡标注「不确定」；schema 拦截占位符，不执行写入。	**使用者本人**
时间 / 地点写错	系统确认框显示可读日期与过期警告；确认后才写入。	**使用者本人**
模型编造工具	白名单拒绝，返回失败原因并记日志；用户可见失败。	**使用者本人**
模型答不上来	明确说「不知道」，不硬编；保留原始输出。	**使用者本人**
导入未知 GGUF	导入前免责：App 只提供本地推理环境，不分发模型。	**使用者本人**

红线：AI 只提供建议与结构化结果，最终决定权永远在人。

App Store：不下载可执行代码 · 模型仅本地推理 · 权限最小化 · 隐私政策 · 无账号与统计 SDK

权限只在工具执行时申请；拒绝授权则功能降级，不影响本地对话。

当前限制：1.7B 复杂推理有限 · 工具只覆盖日历 / 提醒 / 翻译 / 摘要 · Android 未覆盖 · 日期 2/60 错 · 数学 11/69 错

来源：ToolKit 白名单 / schema · 16/16 真机回归 · 日期 60 题 · App Store Review Guidelines 2.5.2 / 5.1.1

一个人 + 一套 AI 工具链，把全栈跑通。

命题书硬性覆盖项 + 接下来的路线；训练队列与发布门禁都写进仓库。

团队分工（按实际填写）

引擎运行时（EngineKit）

模型训练与数据合成

iOS App 与演示

评测与回归

产品与测试

AI 工具使用说明

训练数据：云端教师大模型合成 + SymPy 后验 + 锚点/格式质检

真题转化：官方 CodeBuddy CLI 逐题切题与评分标准转写

开发辅助：编码/文档 AI 协作；对话与提示词可导出复查

第三方资源

llama.cpp（MIT）· Qwen3（Apache 2.0）· sherpa-onnx

Texo 公式识别权重（AGPL-3.0，本仓库同许可）

iOS EventKit / SwiftUI / Vision 系统框架

模型口径：基于 Qwen3 继续训练，不自称自研；提交物 = 10 页 PPT + ≤8 分钟真机 Demo。

路线（已实现 / 进行中 / 规划）

01 **SFT27e CAS 已采用**
58/69，Q5/Q4 已量化

02 **4B 旗舰**
暂缓，等排期；1.7B 容量到顶

03 **iOS 演示壳**
真机 16/16；TestFlight 准备中

04 **本地多 Agent 编排**
Planner + Worker + Verifier；内存预算 + OOM 门禁

05 **Android**
规划中，端侧多平台

GitHub: github.com/fanyifan090409-dev/mobile-llm-engine · 回归 / 跑分 / 训练日志随仓库提供

把 AI 从云端搬进口袋，把编排权交给学生。

来源：项目仓库 · 训练 / 评测日志 · 第三方许可证（MIT / Apache 2.0 / AGPL-3.0）