题目一 · AI × 科学工程（自定方向）

POCKET INTELLIGENCE

口袋里的 Agent 实验室

A local-first agent lab on a phone

一台 iPhone，跑完整个 Agent 闭环。
不联网，也不把数据交出去。

61.1 tok/s
18 Pro Max · 1.7B Q4

0 上传
推理全程本机

16/16 真机自检
13 场景 + 3 语音



REAL DEVICE / iPhone 18 Pro Max

飞行模式 · 20:30 · Q4_K_M · 4K

樊一凡 · 队长

GitHub: mobile-llm-engine

模型口径：基于 Qwen3 继续训练 · 推理底座 llama.cpp（MIT）

资料：本机训练日志 / 真机跑分 / 16/16 回归 · 2026-11

数据一旦离开设备，控制权就没了。

国际学校 / 美高学生每天遇到的不是「AI 不好用」，而是「不敢用」和「没网用」。

3.29万

个文件，连同修改历史被打包上传

ZCode 事件 · 4.11 亿明文字符 · 2026.09

断网的那一刻，云端助手就消失了。
数据已经离开设备，控制权也是。

改前日期题 15/15 全错 · 模型没有「今天」锚点

我们要的不是更聪明的云端，而是能放在口袋里的控制权。



来源：2026 公开报道（求是网 / 工信部 NVDB、36氪 / 掘金、NDSS 2025） · 本项目评测

一句话，七步，
日历里真的多了一条。

「家长会，明天下午三点，学校，约一小时。」飞行模式下，全部在本机完成。

01	02	03	04	05	06	07
飞行模式	**本地推理**	**工具调用**	**schema**	**系统确认**	**EventKit**	**回读**
彻底断网	1.7B 模型	tool_call JSON	参数校验	用户点允许	真实写入	失败如实报错

TOOL_CALL / 本地生成 · 真机截图

add_calendar_event.json — EngineKit

add_calendar_event.json apps/tool-call

```
{
  "name": "add_calendar_event",
  "arguments": {
    "title": "家长会",
    "start_time": "2026-11-04 15:00",
    "end_time": "2026-11-04 16:00",
    "location": "学校"
  }
}
```

VERIFIED / 真机回归

写入后回读，失败就报错。

16/16	场景 + 语音
21.7s	13 场景套件
1804 MB	峰值内存

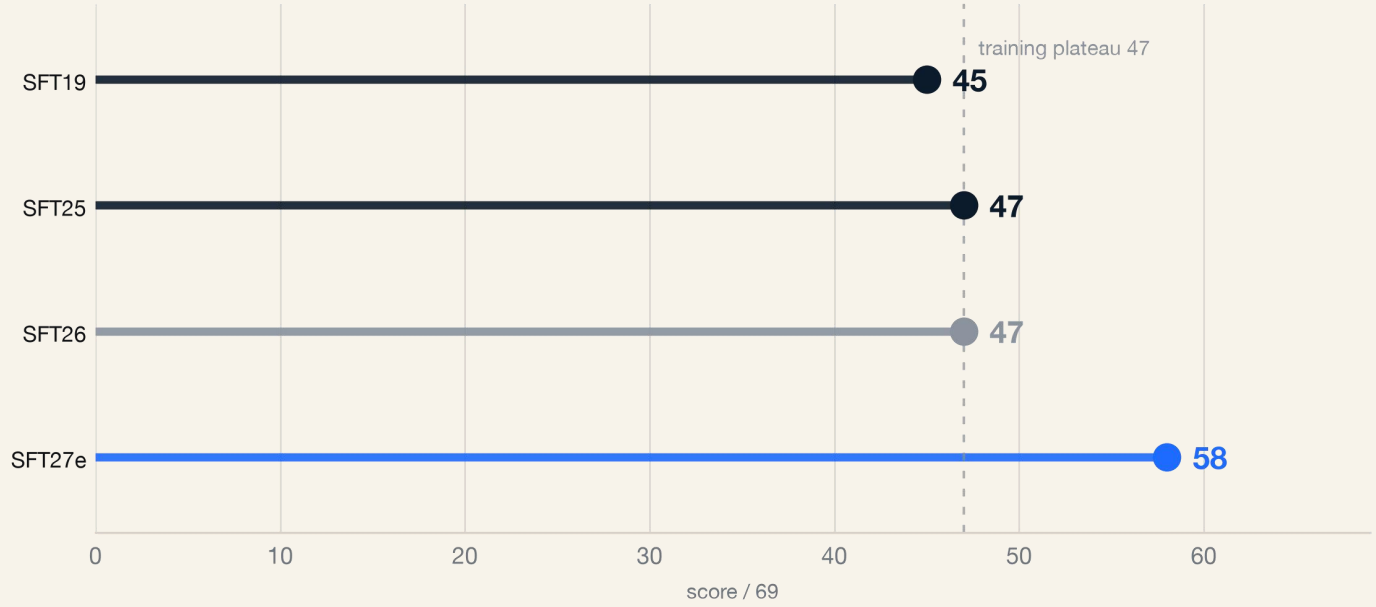
断网也能把事办成——这是云端助手给不了的体验。

来源：EngineKit 真机流程 · 16/16 回归（13 场景 + 3 语音）· 2026-11-09 · PIPL：数据不出设备

训练到顶之后，我们把数学交给工具。

1.7B 的数学容量有上限；继续堆数据没用，改用 CAS 做确定性计算。

MATH / 69 QUESTIONS / OBJECTIVE



SFT26 把 31 道真实 FRQ 训进 1.7B，仍是 47/69；
SFT27e 改走 CAS 工具调用，+11 题。

PURE TRAINING / CEILING

47/69

纯训练路线最高分

31 道真实 FRQ 也没有拉动 1.7B。

不是数据质量，是容量。继续堆同类题会退化。

CAS / 58/69

12.78M	学术训练 tokens	110	SymPy 抓出错解	31	道真实 FRQ

来源：SFT19 / SFT25 / SFT26 / SFT27e 评测 · train/lab-notebook/训练线总览（2026-11-09）

同一套代码，
0.6B / 1.7B 都装进 iPhone。

EngineKit 全 Swift 封装 llama.cpp；模型、上下文、速度档都可换，代价写在界面上。

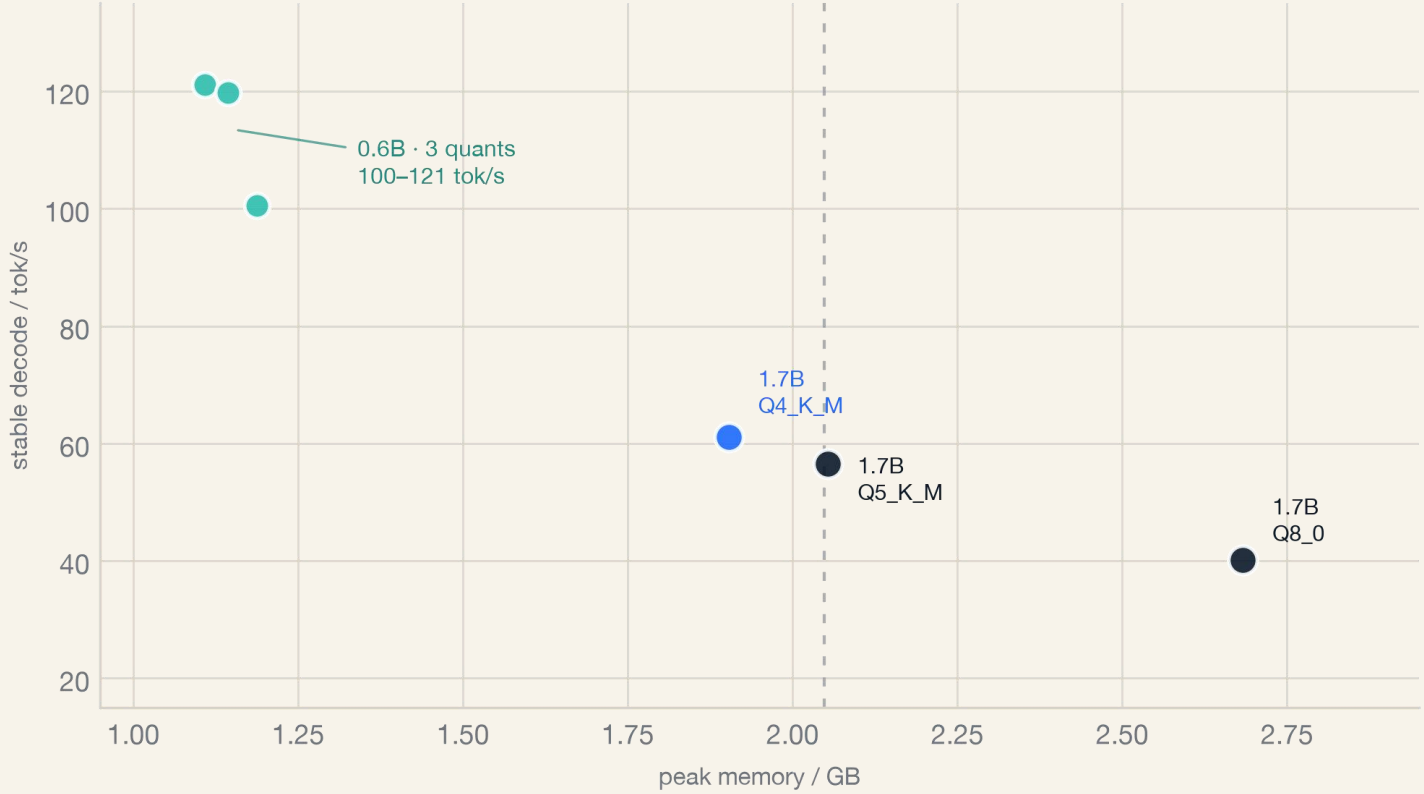
61.1 tok/s

1.7B Q4_K_M · 18 Pro Max · 4K

1.90 GB
峰值内存（4K 上下文）

4K / 8K / 16K / 32K

KV 约 0.44 / 0.88 / 1.75 / 3.5 GB；
8GB 机型建议 ≤8K。



6 档量化实测 · 17/18 Pro Max 同协议 · 4 轮取后 3 轮 · 虚线为 2GB 预算

向下兼容 0.6B，向上预留多 Agent 内存预算。

来源：docs/评测/真机跑分对比-17ProMax-vs-18ProMax-20261103.md · 峰值内存单轮最高

PHOTO IN, PROOF OUT

拍照做题：公式识别 → 本地 CAS → 可复核答案。

Texo 20M 公式识别 + math.js，全程在手机上。

INPUT / 题目图

$$\lim_{x\to 0}\frac{\sin x}{x}$$

ANSWER / math.js

1

本机计算 · 无数值近似

没有网络请求，也没有把题目发给云端。

来源：Texo 18 图对拍（2026-11-09）· SFT27e 69 题端到端 · iPhone 18 Pro Max 真机自检

OCR → PARSED → CAS

OCR / LaTeX

```
\lim_{x\rarr0}\frac{\sin x}{x}
```

题意 / PARSED

求 ((sin(x))/(x)) 在 x→0 时的极限。

58/69

数学端到端

84.1% · SFT27e

69/69

工具发射

schema 全通过

186ms

公式识别（热）

18 Pro Max

18/18

Mac 对拍

与 Python 逐字一致

一张照片，三个本机步骤：
识别公式 → 转成题意 → 调用 CAS。

Texo 20M · 77MB · ONNX Runtime 1.28

40 道工具题，
40/40 全部正确发射。

命题书要求「用测试证明有没有用」——每次调用都落成 case 文件。

40/40

tool_call 正确发射 · 1.7B Q5/Q4

30 条训练分布 + 10 条泛化；schema 与 JSON 双 100%。

100%
schema 校验

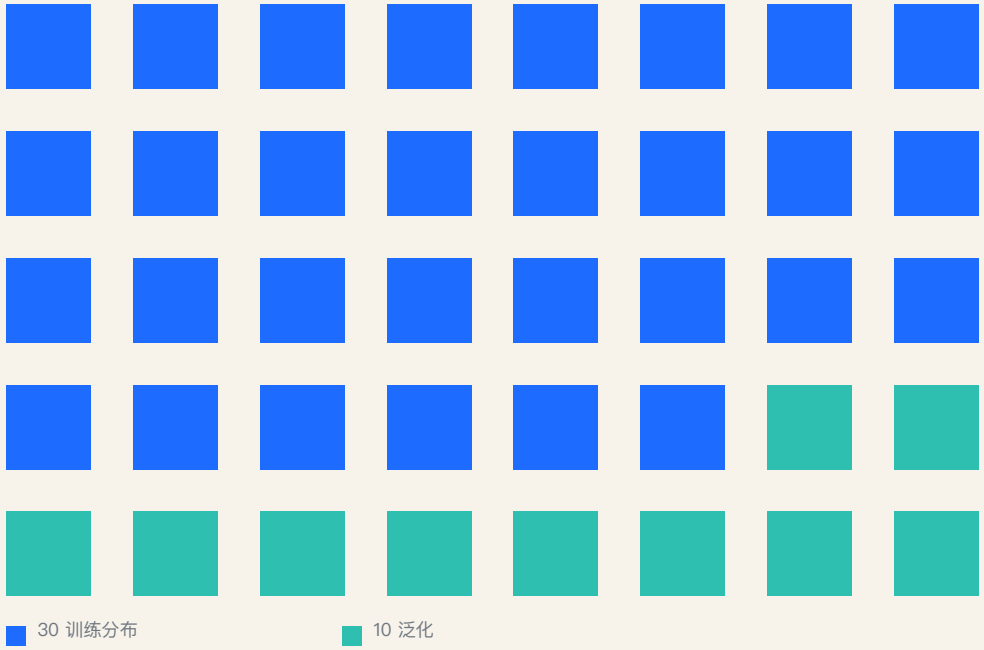
100%
JSON 解析

TOOLS / 白名单

```
add_calendar_event   add_reminder
translate   summarize   clarify
```

白名单外直接拒绝；写入前人工确认。

40 CASES / 30 TRAIN + 10 HELDOUT



不是「感觉能用」，是逐题可复核；
失败样例也保留，能回放。

40/40 不是全场景全对，是这套 40 题全对。

来源：SFT19 评测（40 题，temp 0.7）· SFT3 工具遵循率专项 · 16/16 真机回归

日期题，从 15/15 全错到 58/60。

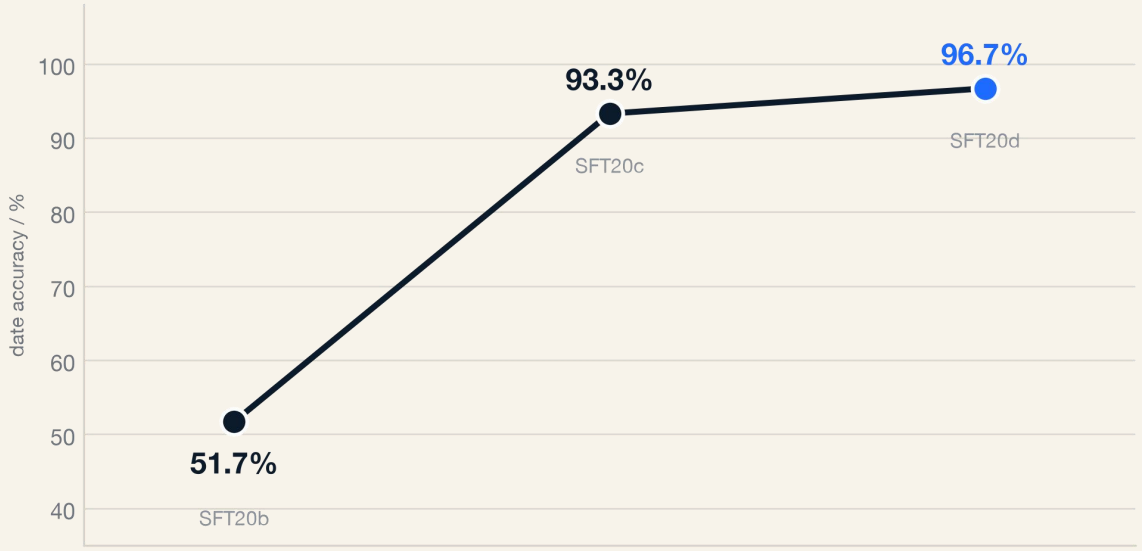
改前 15 题全错；补日期表后把验收集扩到 60 题，再训边界。

58/60

日期题精确匹配 · SFT20d

上一版 93.3%；这一版 96.7%。

96.7%	60 题日期集
16/16	边界题
8/8	工人四工种



SFT20b → SFT20c → SFT20d / 60 题日期集

STILL WRONG / 写进限制

2027-02-29 不存在 → 应滚到 2028；
23:30 + 3h 跨天 → 只加了 1h。

剩下的 2 题写进限制，不假装 100%。

来源：SFT20b / SFT20c / SFT20d 日期评测（60 题，2026-11-08）· 训练线总览

AI 判断错了，产品怎么办?

命题书完成重点：怎样提醒使用者、由谁确认和处理。

DEFENSE IN DEPTH / 四道闸门

01
MODEL
幻觉 / 编造工具
白名单 + 「不确定」标注

02
SCHEMA
参数错 / 时间格式
必填 + 正则，拒绝执行

03
HUMAN
时间 / 地点写错
系统确认框，显示可读日期

04
WRITE
写入失败
回读校验，如实报错

红线：AI 只提供建议与结构化结果，最终决定权永远在人。

写入前弹系统确认框；用户点「允许」才执行。

APP STORE / 合规

不下载可执行代码 · 模型仅本地推理
权限最小化 · 隐私政策 · 无账号与统计 SDK

CURRENT LIMITS / 诚实披露

1.7B 复杂推理有限 · 工具只覆盖日历/提醒/翻译/摘要
Android 未覆盖 · 日期 2/60 错 · 数学 11/69 错

来源: ToolKit 白名单 / schema · 16/16 真机回归 · 日期 60 题 · App Store Review Guidelines 2.5.2 / 5.1.1

09 / TEAM & NEXT

三个人，三个智能体，一条评审链。

队长把产品做出来，队员证明它能跑、别人用得起来；每个产出都经 PR 评审后合并。

TEAM / 分工

姓名 / 角色	智能体承担	人承担
樊一凡 队长 · 架构 / 训练 / 发布	代码骨架 · 调试 · 批量数据处理	**架构决策 · 评审与合并**
张曜阳 队员 · 首次安装体验	整理卡点记录 · 汇总共性问题	**首装走查 · 记录卡点**
薛亦湘 队员 · 用户验证与演示	整理访谈记录 · 起草分镜脚本	**组织同学试用 · 逐条核对数字**

WORKFLOW / 一件任务的全过程

01	02	03	04	05
Issue 任务单	**独立分支**	**提交 PR**	**队长评审**	**合并 main**
目标 · 验收 · 证据	一人一支	附截图与原话	打回或批准	编号进记录

DISCIPLINE / 工程纪律

计划先行 / **门禁全绿** / **16 项真机回归** / **评测结果落盘** / **第三方许可逐项标注**

训练数据：云端大模型 + SymPy 后验 · 真题转化与开发：AI 协作 + 人工复核

ROADMAP / 已实现 · 进行中 · 规划

01	02	03	04	05
CAS	4B	TestFlight	Multi-Agent	Android

来源：项目仓库 · 训练/评测日志 · 第三方许可证（MIT / Apache 2.0 / AGPL-3.0）

CLOSING

把 AI 从云端搬进口袋，把编排权交给学生。

GitHub

`github.com/fanyifan090409-dev/mobile-llm-engine`

提交物 / 10 页 PPT + ≤8 分钟真机 Demo

2026 / AIY HACK LEAGUE