AIY 27 · 高中组 PRO · 题目一 AI×科学工程（自定方向）

口袋里的 Agent 实验室

面向消费级设备的本地 DIY 多 Agent 编排平台

数据不出域 · 美高课程特训 · 日历 / 提醒真实可用 · 一台手机跑起来

不是云端助手的缩小版，而是学生自己的本地 Agent 工作台。

61.1 tok/s	0 上传	13/13 真机回归	10M tokens
稳定解码 · 18 Pro Max	推理全程本机	含时间解析自检	美高课程合成训练

团队：_____　　演示人：_____　　GitHub：mobile-llm-engine

模型口径：基于 Qwen3 继续训练 · 推理底座 llama.cpp（MIT） · 数字来自本机训练与真机日志



数据一旦离开设备，控制权就没了。

国际学校 / 美高学生每天遇到的不是「AI 不好用」，而是「不敢用」和「没网用」。

0

断网时的云端可用性

请求离开设备；断网即失效，数据已经出设备

3.29万

2026 ZCode 事件被上传文件

4.11 亿明文字符，项目连同修改历史打包上传

15/15

改前日期题全错

模型没有「今天」锚点，只能靠心算瞎猜

目标用户：国际学校 / 美高在读学生 + 想学 AI 编排的初学者

我们要的不是更聪明的云端，而是能放在口袋里的控制权。

2026 公开事故（节选）

2026.04–06	Claude Code 安全后门 未经同意回传地域、身份标识等敏感数据	求是网 / 工信部风险提示
2026.09	智谱 ZCode 传包风波 整个项目连同修改历史打包加密上传云端	36氪 / 掘金（企业函件称）
2026.08	PROMPTPEEK 攻击 共享缓存侧信道可还原其他用户提问	NDSS 2025 论文
2026.08	Reasoning Trace Theft 三家 API 加密推理链缺陷，跨模型重放窃取思维链	CSA 研究 / 绿盟分析
2026 上半年	法国医院病历事件 医生用 Claude 3 写病历，8 个月 1247 份	法媒隐私审计报告

来源：2026 年公开报道（求是网 / 工信部 NVDB、36氪 / 掘金、NDSS 2025、CSA / 绿盟、法媒审计）· 用户调研

02 / OPPORTUNITY

云端 AI 的两个硬伤

断网 = 不可用

数据 = 已出设备

输入 → 上传 → 云端推理 → 返回

依赖网络、账号、额度与厂商策略；模型不是你的。

模型不是你的，

数据也不是你的。

03 / LOCAL OPPORTUNITY

本地 AI 的机会

同样一句话，不需要离开设备。

01 输入一句话
同样的任务，不需要联网

↓

02 本地 1.7B 推理
权重在手机里，数据不出设备

↓

03 结构化工具调用
add_calendar_event + 参数

↓

04 schema 校验
格式不对直接拒绝，不执行

↓

05 人确认 → 写入
用户点「允许」才写进系统日历

NEXT / 本地 DIY 多 Agent 编排

从「一个助手」到「一套 Agent 编排」

学生自己拆任务、配角色、看内存代价；当前单 Agent，多 Agent 编排为规划项。



AI 机会 = 1.3GB 权重装进手机后，本地实时推理第一次可用；下一步是把编排权交给用户。

来源：App Store 主流云端助手形态观察 · 本项目 iPhone 18 Pro Max 真机实测（2026-11-03）

一句话，七步，
日历里真的多了一条。

从断网到写入，全程发生在手机本地；每一步都可复核。

用户原话

「家长会，明天下午三点，学校，约一小时」

01 飞行模式
手机彻底断网

02 本地推理
1.7B 模型在手机里

03 工具调用
输出标准 tool_call JSON

04 schema 校验
参数格式不对直接拒绝

05 系统确认
用户点「允许」才执行

06 EventKit 写入
日历里真的多一条

07 回读校验
写不进去就如实报错

完全离线
模型权重与推理都在手机，飞行模式可完整跑通。

工具闭环
不是聊天，是把事办成：日历 / 提醒真实写入系统。

人确认
写入前弹系统确认框，显示可读日期与过期警告。

模型库 / 档位
0.6B / 1.7B、4K–32K、四档速度，逐项标清代价。

13/13	21.7s	1804 MB	42–79
场景回归	全套耗时	峰值内存	tok/s 场景解码

断网也能把事办成——这是云端助手给不了的体验。

PIPL：用户数据不出设备，不收集、不存储对话内容。

来源：iOS 演示壳（EngineKit）真机流程 · 13/13 回归 · 2026-11-03

不追通用榜单，只在美高课程上用真题验收。

数据全部自建：真题转化 + 教师合成 + SymPy 符号验真；SFT19 训练中。

21
AP FRQ 真题
80% 训练 / 20% holdout

10M
tokens 合成数据
ap_calc 40% / precalc 20% / stats 15% / IELTS 25%

110
SymPy 抓出的违规
300 条数值变式 0 错

0/108
AP Calc BC 基线
改前真题得分

01 真题转化
21 道 AP FRQ，逐题切题确认，80/20 划分

02 教师合成
云端教师大模型 + 配比拼装，10M tokens

03 符号验真
SymPy 对拍首轮抓 110 条违规，变式 0 错

04 SFT 训练
1.7B 双卡 · WSD 学习率调度 · LR 消融完成
LR 消融完成

05 真题验收
AP Calc BC holdout ≥85% 才进发布链

已上线 / SFT17

2764 步 · eval 0.535

工具调用 90–97.5% · 真机峰值 1.9GB · 日期题 9/15

在训 / SFT19 美高课程

10M tokens 已合成 · AP Calc BC 0/108 基线 · 3 epochs 训练中

训练完成前不提前宣称提升。



LR 消融：constant 收在 3.12；WSD 1000 步收在 3.07（单次消融，不宣称显著）

训练完成前不宣称提升；验收以 AP Calc BC 真题正确率为门禁。

来源：SFT17 评测报告 · SFT19 / LR 消融训练日志（2026-11-04 01:48）· AP Calc BC 私有真题基线

同一套代码，
0.6B / 1.7B 都装进 iPhone。

EngineKit 全 Swift 封装 llama.cpp；模型、上下文、速度档都可换，代价写在界面上。

61.1 tok/s

稳定解码 · 1.7B Q4_K_M · 18 Pro Max

1.90 GB
峰值内存（4K 上下文）

4K / 8K / 16K / 32K

KV 约 0.44 / 0.88 / 1.75 / 3.5 GB；8GB 机型建议 ≤8K。

档位	17 PM 稳定解码 tok/s	18 PM 稳定解码 tok/s	峰值 MB
1.7B Q4_K_M	38.5	61.1	1903 MB
1.7B Q5_K_M	34.2	56.5	2054 MB
1.7B Q8_0	27.3	40.1	2683 MB
0.6B Q5_K_M	86.9	100.5	1187 MB
0.6B Q4_K_M	89.0	119.7	1144 MB
0.6B IQ4_XS	96.7	121.1	1109 MB

MULTI-AGENT CAPACITY / 规划，待实测

8GB 机型

2–3 个 0.6B Agent 同时在线；再开就进入内存警戒。

12GB 机型

2 个 1.7B + 1 个 0.6B；组合跑分记录峰值与被终止次数。

OOM 门禁

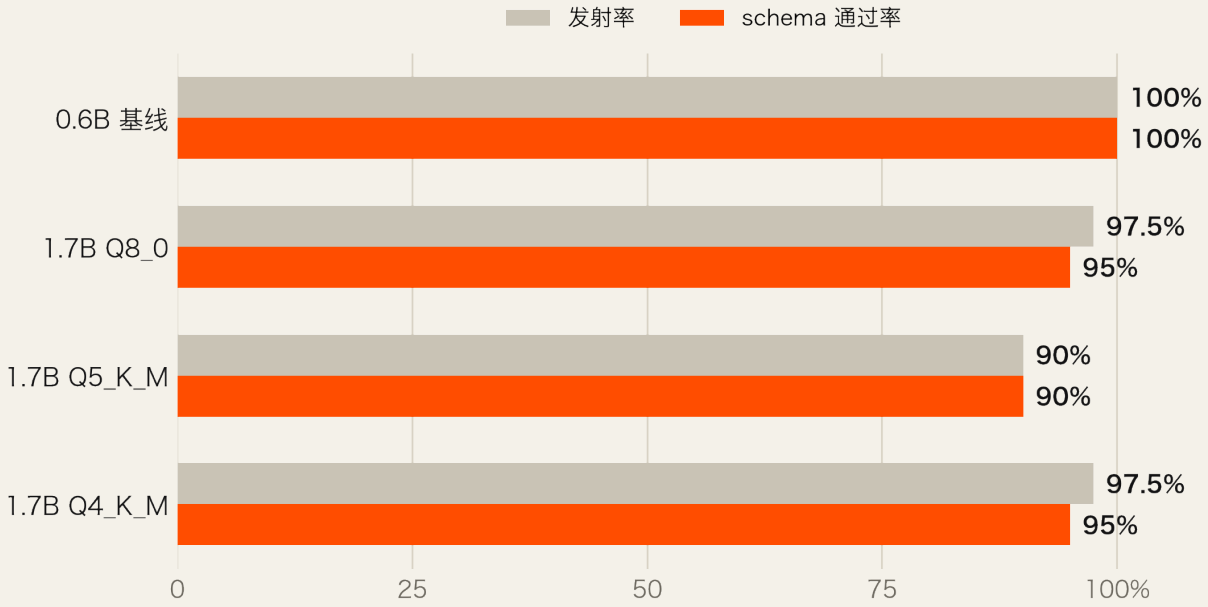
每次组合跑分都测「最多几个不 OOM」，超预算自动降档，不靠拍脑袋。

18 Pro Max 上 1.7B 稳定 61.1 tok/s；同一套代码向下兼容 0.6B、向上预留多 Agent 预算。

口径：4 轮取后 3 轮均值 · 4K · 均衡档 · 峰值内存单轮最高；17 PM 为同协议对比。

40 道工具题，
30/30 训练分布全过。

命题书要求「用测试证明有没有用」——每次工具调用都落成 case 文件。



100%
训练分布 30/30 全过

90—97.5%
schema 通过率（三档量化）

13/13
真机回归（含 1 条时间自检）

10 道泛化题失分，逐条定位：相对日期没把握 / 把确认话当主路径。SFT19 已注入「今天」锚点修复。

真机回归 13/13 · 21.7 秒 · 解码 42–79 tok/s · 峰值 1804 MB

解码为场景瞬时值，不是稳定跑分；稳定值见第 6 页。

不是「感觉能用」，是逐题可复核。

来源：SFT17 评测报告 · 演示壳 Harness 13/13 (2026-11-03)

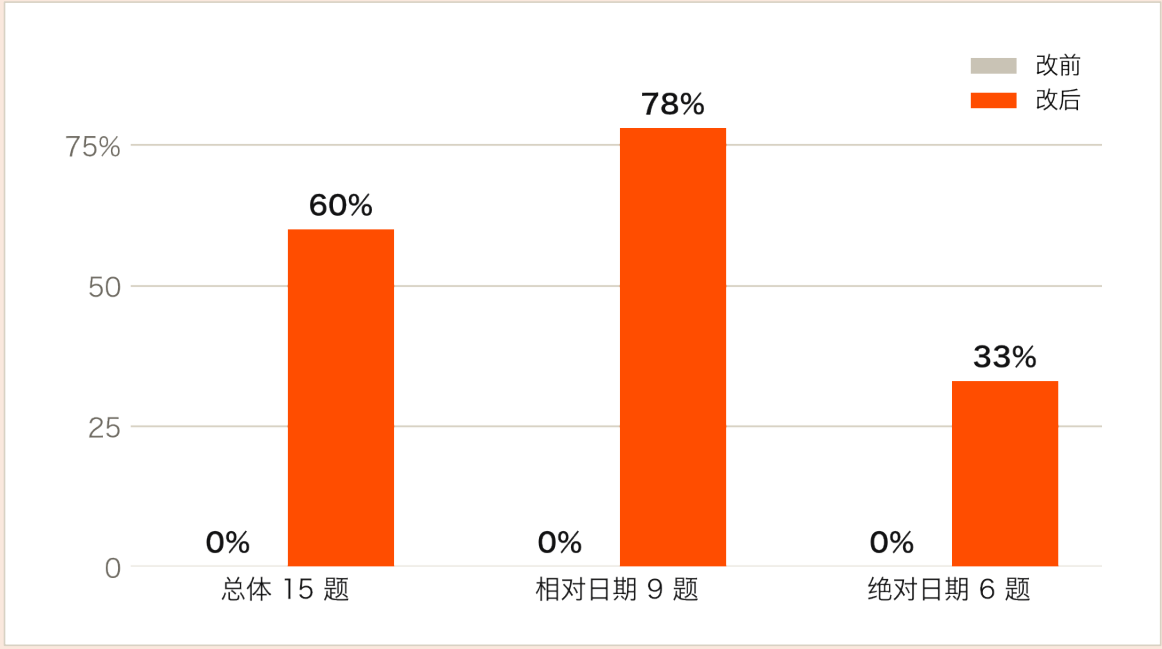
它还会不会瞎编?

问 15 道日期题：改前全错，改后 9 道答对。

9/15

日期题答对（改前 0/15）

还有 6 道会错，产品必须让人确认。



日期题逐题对拍（n=15）

−78%
瞎编次数（相对日期）

14→0
生成问题（复读/截断/空答）

12.29→5.42
目标领域 PPL，越低越顺

训练把它从「全瞎编」拉到「六成能答对」，但没有归零——所以产品必须有确认和兜底。

来源：SFT17 评测报告 §四/§五 · 日期映射 15 题 · 同 Q8_0 档、同 256 max-tokens 对拍

AI 判断错了，产品怎么办?

命题书完成重点：怎样提醒使用者、由谁确认和处理。

风险	产品怎么提醒	谁确认 / 处理
日期 / 事实幻觉	占位符被 schema 拦截；结果卡标注「不确定」，不执行写入。	**使用者本人**
时间 / 地点写错	系统确认框显示可读日期与过期警告；确认后才写入。	**使用者本人**
模型编造工具	白名单拒绝，返回失败原因并记日志；用户可见失败。	**使用者本人**
模型答不上来	明确说「不知道」，不硬编；结果卡保留原始输出。	**使用者本人**
导入未知 GGUF	导入前免责：App 仅提供本地推理环境，不分发模型；需确认许可。	**使用者本人**

红线：AI 只提供建议与结构化结果，最终决定权永远在人。

App Store 合规：不下载可执行代码 · 模型仅本地推理 · 权限最小化 · 隐私政策 · 无账号与统计 SDK

权限只在工具执行时申请；拒绝授权则功能降级，不影响本地对话。

当前限制（诚实披露）：1.7B 复杂推理有限 · 工具只有日历/提醒 · Android 未覆盖 · 美高课程训练中 · 日期仍有 6/15 错

来源：ToolKit 白名单 / schema 实现 · 13 条回归用例 · 日期评测 15 题（SFT17 报告）· App Store Review Guidelines 2.5.2 / 5.1.1

一个人 + 一套 AI 工具链，把全栈跑通。

命题书硬性覆盖项 + 接下来的路线；训练队列与发布门禁都写进仓库。

团队分工（按实际填写）

引擎运行时（EngineKit）：_____

模型训练与数据合成：_____

iOS App 与演示：_____

评测与回归：_____

产品与测试：_____

AI 工具使用说明

训练数据：云端教师大模型合成 + SymPy 后验 + 锚点/格式质检

真题转化：官方 CodeBuddy CLI（云端大模型）逐题切题与评分标准转写

开发辅助：编码/文档 AI 协作；对话与提示词可导出复查

第三方资源

llama.cpp（MIT）· Qwen3 开源模型（Apache 2.0）

iOS EventKit / SwiftUI 系统框架 · 公开中文语料

模型口径：基于 Qwen3 继续训练，不自称自研；提交物 = 10 页 PPT + ≤8 分钟真机 Demo。

路线（已实现 / 进行中 / 规划）

01 **SFT19 美高课程训练**
训练中；AP Calc BC 0/108 基线，3 epochs

02 **量化 + 真题验收**
holdout ≥85% 才进发布链

03 **TestFlight 分发**
模型库/导入/关于与隐私已具备

04 **本地 DIY 多 Agent 编排**
规划中；Planner + Worker + Verifier，内存预算 + OOM 门禁

05 **Android 端**
规划中，端侧多平台

GitHub: github.com/fanyifan090409-dev/mobile-llm-engine · 13 条回归 / 双机跑分 / 训练日志随仓库提供

把 AI 从云端搬进口袋，把编排权交给学生。

来源：项目仓库 · 训练/评测日志 · 第三方许可证（MIT / Apache 2.0）